


Bancos de dados ômicos e clínicos

Disciplina: MTA0034 - Bioinformática aplicada à Medicina

Programa de Pós-Graduação em Medicina Translacional – NPDM/UFC


Thalita Basso Scandolara, PhD

09/09/2026



Quando um dado é "reutilizável"?

FAIR começa antes do código.



Quando um dado é "reutilizável"?

Critérios FAIR

FINDABLE

ID persistente
Título e desenho claros
Amostras identificáveis

ACESSIBLE

Arquivos acessíveis
Restrições declaradas
Método de acesso

INTEROPERABLE

Organismo
Plataforma
Unidades / vocabulário

REUSABLE

Metadados suficientes
Proveniência
Licença

*Tarefa de casa: ler sobre os critérios
FAIR.*


O que são bancos de dados?

Repositórios públicos que **armazenam e disponibilizam** dados biológicos (sequências, expressão, variantes, dados clínicos) de maneira organizada, para consulta e download.

Primário – Registros de Arquivos: Armazenamento de dados brutos experimentais (sequências de DNA, proteínas ou estrutural) não processados; têm um número de submissão (accession number)

Secundário – Bases com Curadoria: Base construída com os dados dos bancos primários; Apresenta curadoria, anotação, e integração; Incluem dados processados e interpretados (ex. vias biológicas)

Híbrido – Bancos compostos: Bancos que misturam primário e secundário; interface user-friendly, ponte entre dados brutos e processados/analísados




O que são bancos de dados?

- **NCBI** (GenBank, dbSNP, ClinVar): sequências, variantes e literatura.
- **GEO**: dados de expressão gênica de milhares de experimentos.
- **SRA**: dados brutos de sequenciamento (*reads*).
- **GTEx Portal**: expressão gênica em tecidos humanos saudáveis.
- **1000 Genomes**: variantes genômicas de populações humanas.
- **gnomAD**: frequências alélicas agregadas de milhares de genomas e exomas.


E inúmeros outros...

De onde vêm os dados de cada banco




Em cada etapa nós “perdemos” informação bruta e “ganhamos” estrutura

De onde vêm os dados de cada banco



Cada etapa gera um dado destinado a um tipo de banco, que o armazena e disponibiliza...

We are
bioinformaticians
thats what we do



Quatro perguntas, quatro blocos

Quem é esse gene?

NCBI Gene

Existe uma coorte pública que testa minha hipótese?

GEO · SRA

Onde esse gene é normalmente expresso?

GTEx

Essa variante ocorre na população?

dbSNP · 1000 Genomes · gnomAD

O que já se disse sobre ela, e como isso se integra a uma coorte?

UCSC Xena · ClinVar

INSTITUIÇÕES ≠ BANCOS DE DADOS

NCBI e EBI são um **ECOSSISTEMA DE RECURSOS**

INSTITUIÇÃO (mantém os dados)

BANCOS DE DADOS (o que ela hospeda)



NCBI

Instituto americano (parte do NIH) que mantém bancos moleculares e biomédicos dos EUA.

Bancos mantidos pelo NCBI

GenBank, dbSNP, ClinVar, GEO, SRA, PubMed.



EMBL-EBI

Braço de bioinformática do EMBL (Europa) que mantém bancos genômicos e proteômicos europeus.

Bancos mantidos pelo EMBL-EBI

ENA, Ensembl, UniProt, ArrayExpress.

International Nucleotide Sequence Database Collaboration



NCBI é uma infraestrutura que reúne diversos recursos biológicos

Organizado por tipo de dado:

- Sequência: Nucleotide, Protein
- Genes e genomas: Gene, Genomes
- Expressão e sequenciamento bruto: GEO, SRA
- Variantes e literatura: ClinVar, PubMed

The screenshot shows the NCBI homepage with a dark blue header containing the NIH logo and the text "National Library of Medicine National Center for Biotechnology Information". A search bar is located below the header. The main content area is divided into several sections: "Welcome to NCBI" with a brief description and links; "Submit", "Download", and "Learn" sections with icons and descriptions; "Develop", "Analyze", and "Research" sections with icons and descriptions; and "Popular Resources" and "NCBI News & Blog" sections on the right. A left sidebar lists various resources like "All Resources", "Chemicals & Bioassays", "Data & Software", etc.

An official website of the United States government [Here's how you know](#)

NIH National Library of Medicine
National Center for Biotechnology Information

All Databases Search

NCBI Home
Resource List (A-Z)
All Resources
Chemicals & Bioassays
Data & Software
DNA & RNA
Domains & Structures
Genes & Expression
Genetics & Medicine
Genomes & Maps
Homology
Literature
Proteins
Sequence Analysis
Taxonomy
Training & Tutorials
Variation

Welcome to NCBI
The National Center for Biotechnology Information advances science and health by providing access to biomedical and genomic information.
[About the NCBI](#) | [Mission](#) | [Organization](#) | [NCBI News & Blog](#) | [Visit the Beta Homepage](#)

Submit
Deposit data or manuscripts into NCBI databases

Download
Transfer NCBI data to your computer

Learn
Find help documents, attend a class or watch a tutorial

Develop
Use NCBI APIs and code libraries to build applications

Analyze
Identify an NCBI tool for your data analysis task

Research
Explore NCBI research and collaborative projects

Popular Resources
[PubMed](#)
[Bookshelf](#)
[PubMed Central](#)
[BLAST](#)
[Nucleotide](#)
[Genome](#)
[SNP](#)
[Gene](#)
[Protein](#)
[PubChem](#)

NCBI News & Blog
[Register for NCBI's Pre-Conference Workshop at ASM BIG 2026](#) 01 Sep 2026
[Are you heading to ASM BIG \(Bioinformatics, Genomics, and Big Data\)](#)
[Interactive Annotation for Viruses Using VADR](#) 31 Aug 2026
NCBI Virus is excited to announce the launch of a web interface for Viral

Vamos explorar o NCBI Gene

Gene ID

Identificador estável. Símbolos mudam; o número não. É o que protege pra planilha exportada: *SEPT4* vira 4-Sep no Excel.

Organism e Orthologs

TP53 humano não é o *Trp53* do camundongo.

Genomic context

A coordenada só existe dentro de uma versão do genoma de referência.

Transcripts

Um gene, vários transcritos. A mesma variante muda de nome conforme o transcrito.

Links (*TP53* p.Arg337His ou R337H)

O Gene aponta para ClinVar, GEO, dbSNP.

NCBI Gene permite encontrar:

- identidade do gene
- Gene ID
- localização cromossômica
- assembly
- transcripts
- proteínas
- literatura relacionada
- referências para outros bancos

Mas não é:

...Um banco de expressão tumoral

..Um banco de frequência populacional

...Um banco exclusivamente de câncer

Lembrem: A *pergunta* define o recurso.

Não podemos começar pelo banco. Devemos começar pela PERGUNTA...



"Data don't make any sense,
we will have to resort to statistics."




"I already wrote the paper.
That's why it's so hard to
get the right data."

Ok, sei o que é um gene. Mas e se eu quiser saber como esse gene se comporta em uma população de amostras?

GEO – Gene Expression Omnibus

Repositório público de dados de expressão e outros experimentos de genômica funcional, incluindo microarranjo (microarray) e RNA-seq.



Buscar somente pelo **gene** geralmente não é a melhor estratégia para encontrar um experimento. Precisamos pensar na **pergunta experimental**.

“melanoma tp53”

“melanoma rna-seq”

RESPONDE

“Existe uma coorte pública com este desenho experimental?”

...NÃO RESPONDE

Se esses dois estudos são comparáveis entre si.

Se esses valores estão prontos para meta-análise.

Se o desenho experimental foi adequado.

*Metadados são descritos pelo submissor. Tecnologia, processamento e lote **diferem** entre estudos!*

GEO

1. GSE (GEO Series) = É o ESTUDO

title; organism; summary; overall design; contributors; publication; samples

2. GSM (GEO Sample) = É uma amostra individual


Contém informações (metadados) daquela amostra em específico

3. GPL (GEO Platform) = É a plataforma tecnologica utilizada no estudo

GEO contempla RNA-Seq, ChIP-Seq, ATAC-seq, microarranjos de expressão e metilação, single-cell...

4. Series Matrix File(s)

5. SRA - Sequence Read Archive



doi: 10.1093/nar/gki022

SRA: Repositório que armazena os dados brutos

GSE → GSM → SRR


GSE: estudo

GSM: amostra

SRR: run de sequenciamento

- *Run*
- *Experiment*
- *Sample*
- *BioProject*
- *BioSample*

Run ≠ sample



Existe uma coorte pública que possa testar minha hipótese?

1. Busquem por doença + tecido + tecnologia
2. Filtrem por *Entry type* = *Series* (pelo estudo, reduz poluição do resultado)
3. Leiam *Overall design*
4. Abram 2-3 GSMs e leiam *Characteristics*
5. Localizem os arquivos suplementares.
6. Vamos abrir um **GEO2R**.

PRA PENSAR

Vocês conseguiriam reconstruir
o desenho experimental
somente pelos metadados?

GEO – GEO2R

Ferramenta emburida no GEO – permite fazer análise de expressão diferencial sem precisar baixar os dados ou escrever códigos

GEO – GEO2R

- Para microarrays, o GEO2R usa *GEOquery* + *limma*;
- Para RNA-seq, utiliza *DESeq2* sobre matrizes de contagens já computadas pelo NCBI

Vantagens:

- Não precisa baixar nada;
- Não precisa saber programar;
- É rápido para triagem;
- Usa ferramentas padrão na área;
- “Reprodutível”: qualquer pessoa pode reabrir o mesmo GSE e refazer a comparação.

Desvantagens:

- Escolhas são pré-configuradas e ocultas (não vai ver a menos que procure qual foi a normalização, filtro ou parâmetro exato aplicados)
- Está analisando com o modelo que a ferramenta decidiu, e não o que você especificou. No R, o modelo e os filtros podem ser explicitados e auditados;
- Não é escalonável: um estudo por vez.
- Use GEO2R para triagem e compreensão inicial; para resultado final, recupere os dados e documente o pipeline.


E se a gente quiser saber onde um
gene é normalmente expresso no
corpo humano?

GTExPortal



[About Adult GTEx](#) [Publications](#) [Access Biospecimens](#) [FAQs](#) [Contact](#)

[Home](#) [Downloads](#) [Expression](#) [Single Cell](#) [QTL](#) [IGV Browser](#) [Tissues & Histology](#) [Documentation](#) [About](#)



The Genotype-Tissue Expression (GTEx) Portal is a comprehensive public resource for researchers studying tissue and cell-specific gene expression and regulation across individuals and development, and species, with data from 3 NIH projects.



The Adult GTEx project is a comprehensive resource of WGS, RNA-Seq, and QTL data from samples collected from 54 non-diseased tissue sites across ~1000 adult individuals.



The Developmental GTEx (dGTEx) project is a new effort to study development-specific genetic effects on gene expression and to establish a new data analysis and tissue biobank resource.




The Non-Human Primate Developmental GTEx (NHP-dGTEx) project is a complement to dGTEx in 2 translational non-human primate model species: the rhesus macaque and common marmoset.






[About Adult GTEx](#)
[Publications](#)
[Access Biospecimens](#)
[FAQs](#)
[Contact](#)

[Home](#)
[Downloads](#)
[Expression](#)
[Single Cell](#)
[QTL](#)
[IGV Browser](#)
[Tissues & Histology](#)
[Documentation](#)
[About](#)



The Genotype-Tissue Expression (GTEx) Portal is a comprehensive public resource for researchers studying tissue and cell-specific gene expression and regulation across individuals and development, and species, with data from 3 NIH projects.



The Adult GTEx project is a comprehensive resource of WGS, RNA-Seq, and QTL data from samples collected from 54 non-diseased tissue sites across ~1000 adult individuals.



The Developmental GTEx (dGTEx) project is a new effort to study development-specific genetic effects on gene expression and to establish a new data analysis and tissue biobank resource.




The Non-Human Primate Developmental GTEx (NHP-dGTEx) project is a complement to dGTEx in 2 translational non-human primate model species: the rhesus macaque and common marmoset.

GTEx

- Expressão por gene/transcrito/éxon
- TPM e contagens
- Metadados de tecido e amostra
- Pra além da expressão: QTL (Quantitative Trait Locus; eQTL e sQTL)

Não vamos analisar isso hoje; quero apenas que vocês saibam que o GTEx também permite estudar efeitos genéticos sobre expressão e splicing



Manzoni, C., Lewis, P.A. & Ferrari, R. Network Analysis for Complex Neurodegenerative Diseases. *Curr Genet Med Rep* 8, 17–25 (2020). <https://doi.org/10.1007/s40142-020-00181-z>

GTEX

Responde: Em que tecidos este gene é expresso (em doadores sem a doença em estudo).

Não responde:

- Que o gene é específico deste tecido.
- Que existe mais proteína aqui.
- Que é assim em tecido vivo.
- Que é assim no meu paciente

Um breve comparativo

GTEX

tecidos humanos normais*

referência de expressão

foco em tecido normal

projeto específico

GEO

muitos tipos de estudos

estudos experimentais

doença/tratamento/etc.

repositório amplo

**GTEX é tecido post-mortem. Tempo de isquemia, RIN e outros fatores afetam a interpretação.*

Tenho uma variante. Ela
ocorre na população?


dbSNP

SNP ▾

Search

[Advanced](#)

[Help](#)



dbSNP

dbSNP contains human single nucleotide variations, microsatellites, and small-scale insertions and deletions along with publication, population frequency, molecular consequence, and genomic and RefSeq mapping information for both common variations and clinical mutations.

Getting Started

[dbSNP 25th Anniversary](#)

[Overview of dbSNP](#)

[About Reference SNP \(rs\)](#)

[Factsheet](#)

[FAQ](#)

[Entrez Updates \(May 26, 2020\)](#)

Submission

[How to Submit](#)

[Hold Until Published \(HUP\) Policies](#)

[Submission Search](#)

Access Data

[Web Search](#)

[eUtils API](#)

[Variation Services](#)

[FTP Download](#)

[Tutorials on GitHub](#)

rs7412 é um endereço

dbSNP: catálogo de variação com identificadores estáveis (rs – reference SNP).

- Um **rs** identifica posição e alelos. Não afirma efeito, não afirma patogenicidade, não afirma frequência.
- Frequência vem de coortes: 1000 Genomes, gnomAD.
- Interpretação clínica vem de submissões: ClinVar.

Mesma variante, três perguntas diferentes, três recursos diferentes

← → ↻ gnomad.broadinstitute.org Install ☆ ABP | Finish update

gnomAD browser gnomAD v4.1.1 Search About Team Federated Stats Policies Publications Blog Changelog Data Forum Contact Help/FAQ

Missed our recent talk on common misconceptions about gnomAD? [Watch the recording](#) covering what the resource is, what metadata are available, and the types of studies it includes.

gnomAD



Genome Aggregation Database

gnomAD v4.1.1 Search by gene, region, or variant

Or

- [Download gnomAD data](#)
- [Read gnomAD publications](#)
- [Find co-occurrence of two variants](#)
- [Browse tandem repeats in gnomAD](#)
- [Locate features not yet in gnomAD v4](#)

Please note that the gnomAD v3 genomes are now part of gnomAD v4. For more information, see ["Should I switch to the latest version of gnomAD?"](#)


- Agregação de **exomas** e **genomas** de muitas coortes, **harmonizados** e **reprocessados** por um **pipeline comum**.
- Publica frequências alélicas, cobertura e métricas de restrição gênica. Não publica genótipos individuais.
- Os grupos de ancestralidade são inferidos dos dados genéticos, não autodeclarados.
- Coortes são incluídas e excluídas por critério: consultar versão



Project Location	Samples	Source	Lead
Africa	TBD	African Genome Variation Database	Nicky Mulder
Australia	10,000	Our DNA	Daniel MacArthur
Brazil	21,000	Genomas SUS	Leandro Colli
Canada	60,000	Canadian Genomic Data Commons	Jordan Lerner-Ellis
China	10,000	Advanced Institute for Information Technology	Xiao Li
Europe	TBD	European Genome Phenome Archive	Abeer Fadda
Europe	30,000	European Reference Network for Rare Neurological Diseases	Holm Graessner
Germany	10,000	Clinical sequencing	Peter Krawitz
Germany	TBD	The German Human Genome-Phenome Archive (GHGA)	Drew Behrens
Japan	100,000	Tomoku Medical Megabank Organization	Soichi Ogishima
Qatar	25,000	Qatar Biobank	Hamdi Mbarek
Singapore	10,000	SG10K_Health data	Maxime Hebrard
Taiwan	1,500	Taiwan Biobank	Jacob Shujui Hsu
UK	50,000	TBD	Vivek Iyer

Supporting open human variation data

Search IGSR



The 1000 Genomes Project created a catalogue of common human genetic variation, using openly consented samples from people who declared themselves to be healthy. The reference data resources generated by the project remain heavily used by the biomedical science community.



Explore the data sets in IGSR through our data portal

The image shows a world map with various regions labeled: North America, South America, Europe, Asia, and Australia. The North Atlantic Ocean is also labeled. Numerous green circular markers with numbers inside are distributed across the map, representing data points. A semi-transparent white box with a blue border contains the text 'Explore the data sets in IGSR through our data portal'.

The Human Genome Structural Variation Consortium (HGSVC), funded by NHGRI, have built on their earlier work published in 2010 and 2021 exploring multiple technologies for structural variation discovery and 30x short-read data generated by NYGC.

This phase of the HGSVC is in progress and expands to additional human genomes using more complete phased assemblies including longer and more accurate long-read sequence data. Raw pre-QC and unvalidated data can be found on the [HGSVC3 IGSR FTP site](#).

Access HGSC data

[View variants in genomic context in Ensembl](#)

		G: 0.849 (163)		GIG: 0.740 (71)			
ASW		A: 0.230 (28) G: 0.770 (94)		AIA: 0.066 (4) GIG: 0.607 (37)		AIG: 0.328 (20)	
ESN		A: 0.066 (13) G: 0.934 (185)		AIA: 0.010 (1) GIG: 0.879 (87)		AIG: 0.111 (11)	
GWD		A: 0.066 (15) G: 0.934 (211)		AIA: 0.009 (1) GIG: 0.876 (99)		AIG: 0.115 (13)	
LW							
MSL		A: 0.009 (1) G: 0.976 (166)		AIA: 0.007 (1) GIG: 0.993 (97)		AIG: 0.000 (0)	
YRI		A: 0.079 (17) G: 0.921 (199)			AIG: 0.157 (17)	GIG: 0.843 (91)	
AMR		A: 0.365 (253) G: 0.635 (441)		AIA: 0.147 (51) GIG: 0.418 (145)		AIG: 0.435 (151)	
CLM		A: 0.452 (85) G: 0.548 (103)		AIA: 0.223 (21) GIG: 0.319 (30)		AIG: 0.457 (43)	


View variants in genomic context in Ensembl

1000 Genomes Project

Referência de diversidade genética humana em diferentes populações.

- ~2.500 pessoas sequenciadas, de 26 populações em 5 continentes
- Mais de 88 milhões de variantes catalogadas (SNPs, indels, variantes estruturais)
- Dados são agrupados por origem (ex.: YRI - Nigéria, CEU - Europeus, CHB – chineses Han):
permite comparar frequências entre grupos
- Versões recentes buscaram corrigir o viés de referências anteriores, baseadas quase só em indivíduos europeus
- PORÉM....populações africanas, sul-asiáticas e indígenas seguem sub-representadas ; resultado não deve ser generalizado para todos os grupos

A frequência de uma variante pode variar entre populações. Portanto, utilizar uma referência populacional inadequada pode afetar a interpretação



Toda frequência tem um denominador

$$AF = AC / AN$$

AC - *allele count*: quantas vezes o alelo foi observado.

AN - *allele number*: quantos alelos foram efetivamente examinados naquela posição.

AN varia por posição e por grupo, porque a cobertura varia. Denominador pequeno, frequência instável.

Por grupo de ancestralidade, AN pode ser pequeno mesmo num banco grande....

Importante: frequência é evidência, não classificação

- Frequência alta em população não selecionada é evidência contra patogenicidade para doença mendeliana grave e de alta penetrância.
- Frequência baixa não é evidência de patogenicidade. A maioria das variantes raras não tem efeito conhecido.
- Ausente no gnomAD significa ausente naquelas coortes, com aquela cobertura.
- Frequência entra na interpretação junto com outras linhas de evidência. Sozinha, não classifica.

Principais diferenças entre os dois bancos

1000 Genomes	gnomAD
projeto populacional	grande referência de variantes humanas
diversidade populacional	frequência/variantes
relativamente menor	muito maior
foco histórico em diversidade	foco forte em referência populacional

Tenho uma coorte de tumores. Quero saber se a expressão deste gene difere entre amostras mutadas e não mutadas, e se isso tem relação com a evolução clínica.

UCSC Xena: integrar diferentes tipos de dados na mesma coorte

Xena é uma plataforma de exploração e visualização de dados genômicos, multi-ômicos e clínicos.

Hub

O servidor que hospeda os dados. Escolhemos de onde vem.

Coorte

Um conjunto de amostras. Ex.: um tipo tumoral do TCGA; tecidos normais do GTEx.

Dataset

Uma matriz dentro da coorte: expressão, mutação, CNV, dado clínico. Cada dataset tem um pipeline e uma unidade.

Amostra

A coluna que une os datasets. A integração acontece porque o identificador de amostra é o mesmo.

Variável

O que você põe em uma coluna do visualizador: um gene, um campo clínico, um subtipo.

...Quem definiu o grupo?

Mutado vs WT: o que conta como mutado?

Missense apenas? Sinônima? Indel? CNV? Depende de qual dataset de mutação você escolheu e de como ele foi chamado.

Alto vs baixo: qual corte?

Mediana, tercil, um valor que você escolheu ao olhar o gráfico? Testar vários cortes e reportar o melhor é um resultado que não se sustenta...

Sobrevida: qual desfecho?

Sobrevida global, sobrevida específica por doença e intervalo livre de progressão respondem a perguntas diferentes e não são intercambiáveis.

A interface aceita todas essas escolhas. É você quem tem que relatar o que foi feito exatamente.

Assistam os tutoriais! =)

UCSC Xena

See the bigger picture


An online exploration tool for public and private,
multi-omic and clinical/phenotype data

Launch Xena

Tutorials and walkthroughs

Don't know where to start? Jump in with one of
our tutorials or "How do I ..." walkthroughs

Tutorials



ClinVar

- Cada linha é a afirmação de um submissor sobre uma variante, para uma condição, com critérios e data próprios.
- O ClinVar arquiva, versiona e agrega essas afirmações; Ele não “decide” qual está certa.
- Duas submissões podem discordar, e as duas continuam no registro.
- Por isso a pergunta certa não é “o que o ClinVar diz”, e sim “quem disse, para qual condição, com base em quê, e quando”.

ClinVar



ClinVar aggregates information about genomic variation and its relationship to human health.

ClinVar

Como a variante foi interpretada?

SCV

Submitted Clinical Variant

Uma submissão: variante +
condição + classificação +
critérios.

RCV / VCV

RCV: variante + condição

VCV: variante

Agregações do ClinVar.

O QUE LER

Classification

Review status

Submitters · critérios · data

Conflitos



[Clear filters](#)

Download

Select Columns

Sort by: Location

Classification type

- ☐ Germline (3)
- ☐ Somatic (3)

Germline classification

- ☐ Conflicting classifications (0)
- ☐ Benign (0)
- ☐ Likely benign (0)
- ☐ Uncertain significance (0)
- ☐ Likely pathogenic (2)
- ☐ Pathogenic (3)

Molecular consequence

- ☐ Frameshift (0)
- ☐ Missense (3)
- ☐ Nonsense (0)
- ☐ Splice site (0)
- ☐ ncRNA (0)
- ☐ Near gene (0)
- ☐ UTR (0)

Variation type

- ☐ Deletion (0)
- ☐ Duplication (0)
- ☐ Indel (0)

Search results: 3 variants for rs121913529

Show 50 entries

Variation	Gene	Type	Condition	Classification, Review status
NM_004985.5(KRAS):c.35G>C (p.Gly12Ala)	KRAS	single nucleotide variant	Familial cancer of breast +15 more	G Pathogenic/Likely pathogenic ★★ S Tier I - Strong ★ O Oncogenic ★
NM_004985.5(KRAS):c.35G>T (p.Gly12Val)	KRAS	single nucleotide variant	RASopathy +9 more	G Pathogenic ★★ S Tier I - Strong ★ O Oncogenic ★
NM_004985.5(KRAS):c.35G>A (p.Gly12Asp)	KRAS	single nucleotide variant	Familial pancreatic carcinoma +23 more	G Pathogenic/Likely pathogenic ★★ S Tier I - Strong ★ O Oncogenic ★

NM_007294.4:c.4675+1G>A



NM_007294.4(BRCA1):c.4675+1G>A

Cite Follow Print Download

- On this page
- Classification Summa
 - Variant Details
 - Genes
 - Germline
 - Conditions
 - Submissions
 - Citations
 - Text-mined Citations

Germline

Reviewed by expert panel
★★★★☆
?

Pathogenic

for Breast-ovarian cancer, familial 1
Classification is based on the expert panel submission
Aug 2015 by Evidence-based Network for the Interpretation of Germline M... ?



Somatic

No data submitted for somatic clinical impact

Somatic

No data submitted for oncogenicity



Variant Details



Identifiers:	NM_007294.4(BRCA1):c.4675+1G>A
	Variation ID: 55256 Accession: VCV000055256.100
Type and length:	single nucleotide variant, 1 bp
Location:	Cytogenetic: 17q21.31 17: 43074330 (GRCh38) [NCBI UCSC] 17: 41226347 (GRCh37) [NCBI UCSC]

Classificação ≠ review status

Classificação: o que foi concluído. Patogênica, provavelmente patogênica, VUS, provavelmente benigna, benigna.

Review status: quanto essa conclusão foi revisada, e por quem. É o que as estrelas mostram.

Patogênica, 1★ - uma conclusão forte com pouca revisão.

VUS, 3★ - uma conclusão de incerteza revisada por painel de especialistas.

Patogênica, 4★ - conclusão forte respaldada por diretriz de prática.

Classificações conflitantes, 1★ - há discordância entre submissores com critérios.

Estrela alta não significa patogênica, e estrela baixa não significa errada...

Mesma variante, quatro afirmações

SUBMISSOR	CLASSIFICAÇÃO	CONDIÇÃO	CRITÉRIOS	DATA
Submissor A	Patogênica	Síndrome X	ACMG/AMP	2019
Submissor B	VUS	Síndrome X	ACMG/AMP	2024
Submissor C	Provavelmente patogênica	Condição Y	sem critérios declarados	2016
Painel de especialistas	Patogênica	Síndrome X	diretriz do painel	2023

Há conflito real ou são condições diferentes?

Qual submissão é a mais recente?

Qual delas declara critérios?

O que o agregado mostra no topo da página?

Uma classificação sem contexto não é suficiente para interpretação

ClinVar

RESPONDE:

O que submissores afirmaram sobre esta variante, para qual condição, com quais critérios e quando.

NÃO RESPONDE

...Qual é a classificação correta.

...Se a variante causa a doença do meu paciente.

...Se a ausência no ClinVar significa variante nova.

....Qual a probabilidade de a classificação estar certa.

Quando sair da web?

Não é fácil vs difícil. É pré-configurado vs controlável.

URL_name	gene_name	plate_coor	row_coor
YBR124W	YBR124W	YB-01	d
YBR094W	YBR094W	YB-01	l
YBR091C	MRS5	YB-01	l
YBR078W	ECM33	YB-01	h
YBR075W	YBR075W	YB-01	h
YBR072W	HSP26	YB-01	h
YBR069C	VAP1	YB-01	h
YBR054W	YR02	YB-01	d
YBR051W	YBR051W	YB-01	d
YBR048W	RPS11B	YB-01	d

It looks like you're trying to do
bioinformatics in Excel.

 Download R

NO R VOCÊ DECLARA

a versão dos dados e do pipeline que você usou
o critério de agrupamento, escrito
o corte, justificado e testado
o modelo, as covariáveis e os contrastes
o método de ajuste e o número de testes
consulta, filtro, parâmetro e semente ficam no script

Os mesmos dados, no R

GEO - baixar a série e os metadados, refazer o contraste com o modelo que você declarou, comparar várias séries.

GEOquery - limma - DESeq2

SRA - recuperar as runs de um estudo e saber exatamente quantas amostras e quantas runs você tem.

GTEX - cruzar expressão por tecido com sua própria lista de genes, em vez de um gene por consulta.

gnomAD - ler o VCF e filtrar milhares de variantes por AF, AN e cobertura de uma vez.

Xena/TCGA/GDC - recuperar a coorte com proveniência, definir os grupos por critério explícito e ajustar o modelo de sobrevida.

UCSCXenaTools - TCGAabioblinks - maftools - survival

Próxima aula

Oncologia de precisão

Plataformas/bancos como cBioPortal,
CIViC, COSMIC

Usaremos o R – pacote *maftools*

